

Autor:

Manuel Eugenio Morocho Cayamcela, Ph.D.

Clasificación con kNN y MLP – Entrenamiento y Despliegue de Modelos

Maestría en Ciencia de Datos y Máquinas de Aprendizaje

Inteligencia Artificial: Data Mining I

Introducción

Esta tarea consiste en entrenar y desplegar dos modelos de clasificación – k-Nearest Neighbors (kNN) y un Perceptrón Multicapa (MLP) – sobre un conjunto de datos de clasificación binaria o multiclase seleccionado por cada equipo. La elección, justificación y calidad del dataset forman parte de la calificación.

Objetivo General

Aplicar técnicas de clasificación supervisada (kNN y redes neuronales tipo MLP) sobre un dataset propio, evaluando y comparando su desempeño, y desplegar el modelo resultante en un entorno accesible para el usuario final.

Objetivos Específicos

- Seleccionar y justificar un dataset propio del equipo, adecuado para un problema de clasificación.
- Realizar el análisis exploratorio del dataset elegido.
- Implementar y evaluar un modelo de clasificación kNN.
- Diseñar, entrenar y evaluar un modelo MLP (scikit-learn ó Keras) para clasificación.
- Comparar el desempeño de ambos modelos.
- Desplegar el modelo entrenado en Excel o en una aplicación Streamlit, documentando el proceso con capturas de pantalla.

Metodología

1. Selección y exploración inicial del dataset

1. Cada equipo selecciona un dataset de clasificación (binaria o multiclase), distinto para cada grupo, justificando su elección: origen, relevancia, tamaño y tipo de variables.
2. Carga del dataset, revisión de estructura, tipos de datos, valores faltantes y estadísticas descriptivas básicas.

2. Selección y visualización de variables

1. Selección de las variables predictoras y la variable objetivo (clase).
2. Visualización exploratoria: distribución de variables, correlaciones, balance de clases, etc.

3. Modelo kNN

1. Preprocesamiento de los datos: escalado/normalización y codificación de variables categóricas si aplica.
2. Selección del valor de k, por ejemplo, mediante validación cruzada o análisis de exactitud vs. k.
3. Entrenamiento del modelo kNN.

4. Evaluación: exactitud, matriz de confusión y probabilidades o votos de vecinos por clase cuando aplique.

4. Modelo MLP

1. Construcción de un MLP simple: input según el número de características seleccionadas, capas ocultas con ReLU y salida con Sigmoid para clasificación binaria o Softmax para clasificación multiclase.
2. Entrenamiento: función de pérdida BCE o Cross-Entropy según el caso, optimizador Adam, número de épocas y batch size.
3. Evaluación: exactitud en test y probabilidades predichas.
4. Visualización: curva de pérdida por época, comparación de predicciones con datos reales y subplots con algunas predicciones correctas e incorrectas.

5. Comparación y análisis

1. Comparar kNN y MLP en términos de exactitud, matriz de confusión y probabilidades predichas.
2. Analizar ventajas y limitaciones de cada método sobre el dataset elegido.
3. Reflexionar sobre cómo los modelos podrían aplicarse en un contexto real relacionado con el dataset.
- 4.

Despliegue del modelo

El equipo debe desplegar el modelo con mejor desempeño, o ambos si lo desea, en una de las siguientes dos modalidades:

- **Excel:** hoja de cálculo interactiva donde el usuario ingresa los valores de las variables y obtiene la predicción mediante fórmulas, o una macro/VBA que invoque el modelo exportado.
- **Streamlit:** aplicación web sencilla que cargue el modelo entrenado, serializado por ejemplo con joblib y permita ingresar nuevos datos para obtener la predicción en tiempo real.

En ambos casos se deben incluir capturas de pantalla del despliegue en funcionamiento —interfaz, ingreso de datos y resultado de la predicción— dentro del informe PDF.

Preguntas reflexivas

1. ¿Por qué eligieron este dataset y qué particularidades tiene frente a otros conjuntos de datos de clasificación?
2. ¿Qué criterios utilizaron para seleccionar las variables predictoras?
3. ¿Cómo influyó el valor de k en el desempeño del modelo kNN?
4. ¿Cómo influyó el número de capas y neuronas en la red neuronal (MLP) en el desempeño del modelo?
5. ¿Qué modelo (kNN o MLP) les pareció más adecuado para este conjunto de datos y por qué?
6. ¿Qué ventajas y dificultades encontraron al desplegar el modelo en Excel o Streamlit?
7. ¿Cómo podrían usarse los resultados de los modelos en decisiones reales relacionadas con el dominio del dataset elegido?

Entregables

- **Notebook de Jupyter (.ipynb)** con código comentado del preprocesamiento, kNN y MLP, visualizaciones y tablas de predicciones.
- **Informe PDF** con explicación del análisis realizado, justificación del dataset elegido, resultados comparativos entre kNN y MLP, capturas de pantalla del despliegue y respuestas a las preguntas reflexivas.
- **Artefacto de despliegue:** archivo Excel funcional o enlace/código de la app Streamlit.

Rúbrica de evaluación

1. Selección y exploración del dataset. Elección de un dataset propio del equipo, justificación de su pertinencia, carga correcta, revisión de estructura, tipos de datos, valores faltantes y estadísticas básicas. **Cumple:** CUMPLE / NO CUMPLE.

2. Selección, justificación y visualización de variables. Elección razonada de las variables predictoras para la tarea de clasificación, con visualizaciones exploratorias de distribución, correlación, balance de clases, etc. **Cumple:** CUMPLE / NO CUMPLE.

3. Implementación del modelo kNN. Preprocesamiento adecuado, escalado, selección justificada de k, por ejemplo validación cruzada, entrenamiento y evaluación con exactitud y matriz de confusión. **Cumple:** CUMPLE / NO CUMPLE.

4. Implementación del modelo MLP. Diseño de la arquitectura, capas, neuronas, activaciones, entrenamiento con función de pérdida, optimizador y épocas, curva de pérdida y evaluación en test. **Cumple:** CUMPLE / NO CUMPLE.

5. Comparación entre kNN y MLP. Comparación de exactitud, matriz de confusión y probabilidades/predicciones; análisis de ventajas y limitaciones de cada método sobre el dataset elegido. **Cumple:** CUMPLE / NO CUMPLE.

6. Despliegue del modelo. Despliegue funcional en Excel o Streamlit, incluyendo capturas de pantalla que muestren la interacción y el resultado de una predicción. **Cumple:** CUMPLE / NO CUMPLE.

7. Respuestas reflexivas. Respuestas completas, coherentes y fundamentadas a las preguntas asignadas. **Cumple:** CUMPLE / NO CUMPLE.

8. Entregables (Notebook y PDF). Notebook (.ipynb) y PDF entregados de forma organizada, con código comentado, gráficos, tablas de predicciones, comentarios y conclusiones. **Cumple:** CUMPLE / NO CUMPLE.